مقایسهٔ روش‌های Routing روی RouterBench

۱. RouterBench چیست

RouterBench یک دیتاست آماده است که شرکت Martian منتشر کرده. ایدهٔ آن ساده است: ۳۶,۴۸۱ سؤال را به ۱۱ مدل زبانی داده‌اند، جواب هر مدل را ثبت کرده‌اند، نمره داده‌اند، و هزینهٔ دلاری هر جواب را هم نوشته‌اند. نتیجه یک جدول بزرگ است که برای هر سؤال، نمره و هزینهٔ هر ۱۱ مدل را دارد.

این یعنی برای آزمایش یک router لازم نیست مدلی را صدا بزنیم. router سؤال را می‌بیند، یک مدل انتخاب می‌کند، و ما نمره و هزینهٔ همان مدل را از جدول برمی‌داریم. به همین دلیل توانستیم صدها هزار تصمیم را در چند دقیقه و با هزینهٔ صفر بسنجیم. سؤال‌ها به دو بخش تقسیم شدند: ۲۹,۱۸۵ برای آموزش و ۷,۲۹۶ برای آزمون (held-out). همهٔ عددهای این گزارش روی بخش آزمون است.

مدل	ارائه‌دهنده	نمرهٔ میانگین	هزینهٔ هر سؤال ($)	یادداشت
gpt-4-1106-preview	OpenAI	78.11%	0.003270	بهترین و گران‌ترین
zero-one-ai/Yi-34B-Chat	Together	65.37%	0.000186	بهترین نسبت نمره به هزینه
claude-v2	Anthropic	63.60%	0.002415	
claude-v1	Anthropic	62.74%	0.002130	
gpt-3.5-turbo-1106	OpenAI	62.29%	0.000243	
claude-instant-v1	Anthropic	60.26%	0.000233	
mistralai/mixtral-8x7b-chat	Together	54.78%	0.000134	
WizardLM/WizardLM-13B-V1.2	Together	43.71%	0.000073	
meta/llama-2-70b-chat	Together	33.80%	0.000203	
mistralai/mistral-7b-chat	Together	30.40%	0.000046	ارزان‌ترین
meta/code-llama-instruct-34b-chat	Together	20.11%	0.000172	

نمره و هزینه: میانگین روی ۷,۲۹۶ سؤال آزمون. فاصلهٔ قیمت بین ارزان‌ترین و گران‌ترین مدل ۷۰ برابر است.

سؤال‌ها از benchmarkهای شناخته‌شده جمع شده‌اند. ترکیب آنها مهم است، چون هر عددی که در ادامه می‌بینی مخصوص همین ترکیب است:

benchmark	سهم سؤال‌ها	چه نوع سؤالی	نمره چه شکلی است
MMLU	38.5%	دانش عمومی و تخصصی، ۵۷ رشته، چهارگزینه‌ای	۰ یا ۱ — حرف گزینه درست است یا نه
HellaSwag	27.5%	ادامهٔ منطقی یک جمله، چهارگزینه‌ای	۰ یا ۱
GSM8K	20.4%	ریاضی دبستان، جواب عددی	۰، ¼، ½، ¾، ۱ — چند بار اجرا شده
ARC, WinoGrande, MBPP	8.7%	علوم، عقل سلیم، کدنویسی	۰ یا ۱
زیرمجموعه‌های چینی	2.4%	شعر، معما، ترجمه	۰ یا ۱
MT-Bench	0.3%	گفت‌وگوی باز	۰/۱ تا ۱ — با judge

۲. سه نقطهٔ مرجع: کف، سقف، و شانس

عدد یک router به‌تنهایی معنی ندارد. «۷۸٪» خوب است یا بد؟ فقط وقتی می‌شود گفت که بدانیم بدون هیچ هوشی چه می‌گیریم و با هوش کامل چه می‌گرفتیم. سه مرجع همیشه کنار هر عدد هست:

مرجع	یعنی چه	نمره	هزینه ($)	چطور به‌دست آمد
سقف (oracle)	برای هر سؤال، از قبل بدانیم کدام مدل درست جواب می‌دهد و ارزان‌ترینِ آنها را انتخاب کنیم. در واقعیت ممکن نیست، چون باید جواب همه را ببینیم.	91.43%	0.000230	بیشترین نمرهٔ هر سطر جدول
کف (best constant)	هیچ routing نکنیم و همیشه یک مدل ثابت را صدا بزنیم. بهترین مدل ثابت gpt-4 است. هر router که از این بهتر نباشد، فقط پیچیدگی اضافه کرده.	78.11%	0.003270	میانگین ستون gpt-4
شانس (random)	برای هر سؤال یک مدل تصادفی. اگر router از این بهتر نباشد، اصلاً کار نمی‌کند.	51.75%	0.000849	انتخاب تصادفی یکنواخت

> فاصلهٔ کف تا سقف ۱۳٫۳۲ واحد درصد است. این کل فضایی است که routing می‌تواند برنده شود. هر روشی که بسازیم، جایی بین ۷۸٫۱۱ و ۹۱٫۴۳ می‌افتد.

یک نکته دربارهٔ سقف: در ۸۲٪ سؤال‌ها یک مدل ارزان درست جواب می‌دهد و gpt-4 فقط در ۲٫۱٪ واقعاً لازم است. یعنی سقف نه‌تنها نمرهٔ بالاتری دارد، بلکه ۱۴ برابر ارزان‌تر از کف است. پول در همین‌جاست.

۳. کیفیت چطور اندازه گرفته می‌شود

تصور کن یک امتحان ۷٬۲۹۶ سؤالی داریم. یازده دانش‌آموز (همان ۱۱ مدل) قبلاً همهٔ سؤال‌ها را جواب داده‌اند و برگه‌هایشان تصحیح شده. ما به آنها دسترسی نداریم که دوباره بپرسیم؛ فقط برگه‌های تصحیح‌شده را داریم.

کار router این است که برای هر سؤال — بدون دیدن جواب‌ها، فقط با خواندن متن سؤال — بگوید «از این دانش‌آموز کپی کن». نمرهٔ router میانگین درستیِ جواب‌هایی است که کپی کرده. یک سؤال واقعی از دیتاست:

سؤال MMLU (حقوق): «کدام قانون بر این قرارداد حاکم است؟ / A / B / C / D» — جواب درست: B

مدل	چه گفته	نمره
gpt-4	B	1
Yi-34B	B	1
gpt-3.5	C	0
mistral-7b	A	0

router متن سؤال را می‌بیند و مثلاً می‌گوید «Yi-34B». نمرهٔ Yi-34B روی این سؤال را از جدول برمی‌داریم: ۱. هزینه‌اش را هم: $0.00019. اگر گفته بود «gpt-3.5»، نمره ۰ می‌شد.

این را ۷٬۲۹۶ بار تکرار می‌کنیم و میانگین می‌گیریم. همین است. نه LLM-judge، نه نظر انسان، نه چیزی دربارهٔ طول یا سبک جواب — فقط درست یا غلط به تعریف خود benchmark.

سه نکته که باید در ذهن باشد:

- ۷۸٪ یعنی میانگین نمره، نه «۷۸٪ جواب کاملاً درست». سؤال‌های ریاضی نمرهٔ جزئی دارند (¾ یعنی سه بار از چهار بار درست). ۷۹٪ همهٔ خانه‌های جدول دقیقاً ۰ یا ۱ هستند؛ بقیه نمرهٔ جزئی است.
- مقایسه‌ها cost-matched هستند. هر router یک پیچ تنظیم دارد از «ارزان‌ترین» تا «بهترین». برای مقایسهٔ منصفانه با کف، پیچ را جایی می‌گذاریم که هزینه‌اش از gpt-4 بیشتر نشود، و نمره را همان‌جا می‌خوانیم.
- هر تفاوتی یک بازهٔ اطمینان دارد. چون بیشتر نمره‌ها ۰ یا ۱ هستند، اعداد حدود ±۰٫۲ واحد لرزش ذاتی دارند. کنار هر تفاوت، بازهٔ ۹۵٪ (CI95) با bootstrap جفتی و ۲۰ هزار نمونه‌گیری آمده. اگر بازه صفر را در بر بگیرد، تفاوت ثابت نشده — حتی اگر عدد بزرگ به‌نظر برسد.

۴. نُه روش، کنار هم

از یازده روش سند «Advanced LLM Routing Methodologies»، نُه روش پیاده و روی همان ۷٬۲۹۶ سؤال آزمون سنجیده شد. دو روش دیگر (Entropy Cascade و Speculative Verification) به داده‌ای نیاز دارند که RouterBench ندارد. همه cost-matched با کف، و همه با یک تابع انتخاب یکسان، تا تفاوت نتیجه از کیفیت پیش‌بینی بیاید نه از سیاست انتخاب.

#	روش	نمره	هزینه ($)	صرفه	Δ vs کف	CI95	تصمیم (ms)	حکم
1	Router-BERT	78.74%	0.002476	24%	+0.63	[+0.24, +1.03]	15.2 (GPU)	**بهتر از کف، ارزان‌تر**
6	Token-Budget	78.70%	0.002708	17%	+0.59	[+0.24, +0.94]	1.55	**anchor = با هزینهٔ ۱٫۶٪ کمتر**
5	Anchor	78.67%	0.002751	16%	+0.57	[+0.22, +0.91]	0.64	**بهتر از کف، ارزان‌تر، سریع‌ترین**
8	Meta-Routing	78.61%	0.002782	15%	+0.50	[+0.19, +0.81]	1.60	**anchor = تقسیم؛ به دامنه سودی نداد**
10	KNN	77.81%	0.002483	24%	−0.29	[−0.75, +0.16]	17.9	**برابر کف، ارزان‌تر، ولی کند**
2	Matrix Factorization	76.55%	0.002895	11%	−1.56	[−2.03, −1.10]	0.72	**بدتر از کف**
9	Reward-Model	64.71%	0.002151	34%	−13.40	[−14.41, −12.40]	1.46	**خیلی بدتر — پایین توضیح داده شده**
11	Bandit	79.40%	0.002723	17%	—	—	~0.7	**روش کار فرق دارد: online یاد می‌گیرد**
4	Dynamic Threshold	78.36%	0.001635	50%	—	—	~0.7	**روش کار فرق دارد: با budget ثابت**

سبز: بهتر از کف با CI که صفر را رد می‌کند. قرمز: بدتر از کف. زرد: قابل مقایسهٔ مستقیم نیست (پایین). ستون «تصمیم»: زمان هر تصمیم روی سرور، یک سؤال در هر بار.

سه ردیف توضیح جدا می‌خواهند:

- **(۱۱) Bandit روی جریان آزمون *یاد می‌گیرد* — بعد از هر سؤال نمره را می‌بیند و خودش را اصلاح می‌کند. عدد ۷۹٫۴۰٪ نمرهٔ ربع آخر جریان است، وقتی یادگیری جا افتاده. برتری کوچکش نسبت به anchor از همین بازخورد می‌آید که routerهای دیگر ندارند. شروع سرد (بدون تاریخچه) حدود ۱۲ واحد ضرر روی کل جریان دارد — هزینهٔ اضافه کردن مدلی که سابقه ندارد.**
- **(۴) Dynamic Threshold با یک budget ثابت کار می‌کند و پیچ را بعد از هر سؤال بر اساس پول باقی‌مانده تنظیم می‌کند. عدد ۷۸٫۳۶٪ با نصف خرج gpt-4 به‌دست آمده — بالاتر از خود gpt-4 — و خرج نهایی با خطای ۰٫۲٪ روی budget نشست.**
- **۱۳ (۹) Reward-Model واحد باخت، و علتش آموزنده است: reward model به جواب‌های *بلند* نمره می‌دهد (همبستگی +۰٫۵۵ با طول)، در حالی که درستی به طول بی‌اعتناست (+۰٫۰۳). روی امتحانی که جواب درست اغلب یک حرف است، router به سمت مدل‌های پرحرف می‌رود. برای gpt-4 حتی همبستگی منفی است: جواب‌های کوتاهِ درستش پایین‌تر از جواب‌های بلندِ غلطش نمره می‌گیرند.**

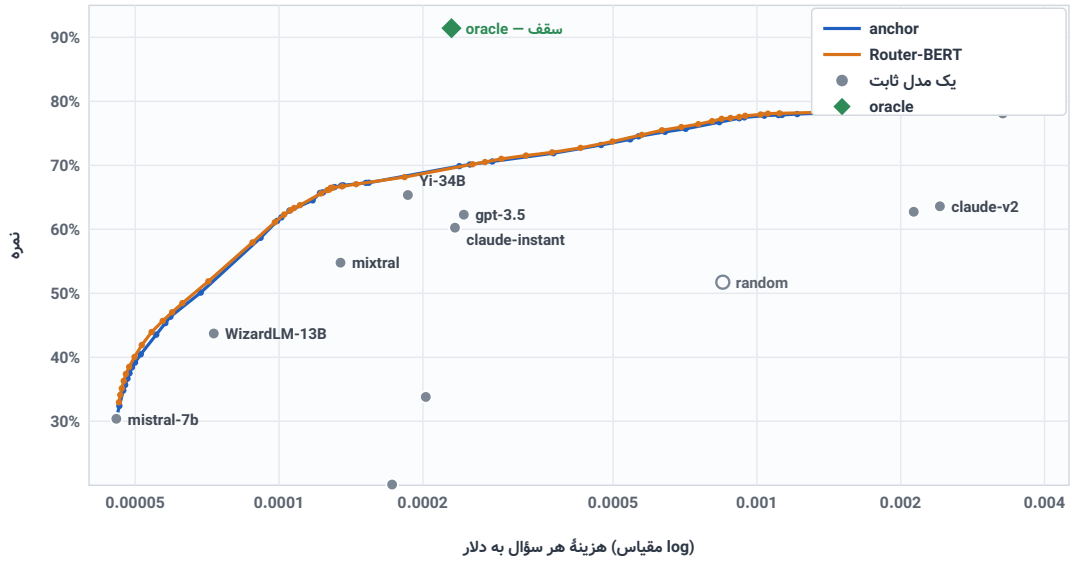
دو نتیجهٔ منفی دیگر: Meta-Routing با شش دامنه حتی وقتی دامنهٔ واقعی را به آن دادیم، در فاصلهٔ ۰٫۰۵ واحد از یک anchor سراسری ماند — تقسیم به دامنه سودی ندارد. و ترکیب روش‌ها (میانگین BERT و anchor و KNN، با وزن، با gating) در بهترین حالت +۰٫۱۰ واحد داد که در نویز است؛ وزن یادگرفته‌شده برای KNN صفر بود.

۵. دو برنده: anchor و BERT

جدول بالا BERT را ۰٫۰۷ واحد جلوتر از anchor نشان می‌دهد. این یک نقطه است. وقتی همان دو router را روی کل منحنی — در هفت budget مختلف، جفتی روی همان سؤال‌ها — مقایسه کنیم:

budget (نسبت به خرج gpt-4)	anchor	BERT	BERT − anchor	CI95	حکم
5%	67.28%	67.05%	−0.23	[−0.84, +0.39]	تساوی
10%	70.61%	71.00%	+0.39	[−0.24, +1.04]	تساوی
20%	75.23%	75.49%	+0.26	[−0.25, +0.78]	تساوی
30%	77.48%	77.75%	+0.26	[−0.01, +0.54]	تساوی (مرزی)
50%	78.30%	78.34%	+0.04	[−0.29, +0.37]	تساوی
75%	78.60%	78.80%	+0.19	[−0.08, +0.47]	تساوی
100%	78.67%	78.83%	+0.15	[−0.12, +0.43]	تساوی

هفت budget، هفت تساوی. BERT در شش‌تا کمی جلوتر است ولی هیچ‌جا از صفر عبور نمی‌کند. از زاویهٔ هزینه: برای رسیدن به ۷۰ تا ۷۴٪ نمره، anchor یک تا شش درصد ارزان‌تر است؛ برای ۷۶ تا ۷۸٪، BERT ده تا سیزده درصد. یعنی برتری BERT، اگر باشد، فقط در بالای منحنی است.



نمودار Pareto: هر نقطه روی منحنی یک تنظیم از پیچ router است. هر چه بالاتر و چپ‌تر، بهتر. دو منحنی تقریباً روی هم افتاده‌اند؛ هر ۱۱ مدل ثابت زیر آنها هستند؛ oracle در گوشهٔ بالا-چپ نشان می‌دهد چقدر جا مانده.

چیزی که این دو را واقعاً جدا می‌کند، کیفیت نیست:

anchor		BERT
زمان هر تصمیم	0.64 ms	15.2 ms
سخت‌افزار	CPU، فقط numpy	GPU
آموزش	چند ثانیه (k-means)	۱۰ دقیقه GPU (fine-tune)
هزینهٔ اجرای خودِ router	نزدیک صفر	یک GPU روشن — در هیچ ستون هزینهٔ این گزارش نیست؛ آن ستون‌ها فقط هزینهٔ مدل‌های کاندید را می‌شمارند
بودجهٔ طراحی (p99 ≤ 25 ms)	۴۰ برابر زیر بودجه	داخل بودجه، ولی زیر بار می‌تواند تنگ شود

حکم: با کیفیت برابر، anchor انتخاب عملی است — ۲۴ برابر سریع‌تر، بدون GPU، بدون آموزش سنگین. BERT را وقتی بردار که در بالاترین نقطهٔ منحنی کار می‌کنی و ۱۰٪ صرفه در خرج مدل‌ها بیشتر از هزینهٔ نگه‌داشتن یک GPU برای router است.

این عددها روی همین ترکیب benchmark است. امتحانی با وزن متفاوت — مثلاً کدنویسی بیشتر — عدد مطلق هر router را عوض می‌کند. ترتیب نسبی احتمالاً می‌ماند، ولی این خودش ادعایی است که باید تست شود.