تست routing و cascading روی مدل‌های ArvanCloud

۱. دیتا

150	14	10	60	90
سؤال مشترک	حوزهٔ موضوعی	گزینه در هر سؤال	سؤال train	سؤال held-out

دیتاست MMLU-Pro است: ۱۲,۰۳۲ سؤال ده‌گزینه‌ای در ۱۴ حوزه. نمونه‌گیری متوازن انجام شد — ۱۱ سؤال از هر حوزه، جمعاً ۱۵۴ سؤال، که ۱۵۰ تای آن را هر ۷ مدل کامل جواب دادند. یک نمونهٔ واقعی از حوزهٔ `business`:

یک بیمه‌نامهٔ خودرو در ۱۰ مارس با حق بیمهٔ ۱۵۵ دلار خریداری شده و در ۶ سپتامبر توسط مالک خودرو فسخ شده است. مبلغ بازگشتی چقدر است؟

A $100 | B $155 | C $30 | D $110 | E $93 | F $125 | G $180 | **H $62** | I $45 | J $77

از مدل خواسته می‌شود در انتهای پاسخ دقیقاً خطی به شکل `The answer is (X)` بنویسد و همان حرف استخراج و با کلید مقایسه می‌شود. هیچ judge ای در کار نیست.

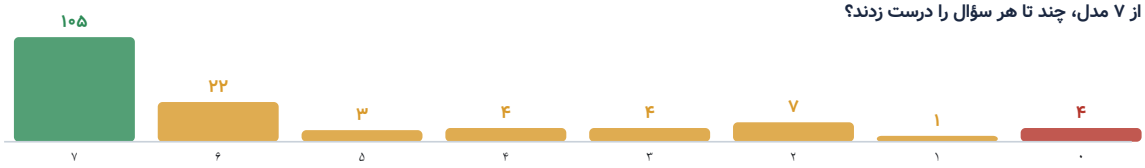
جوابی که هر ۷ مدل به همین سؤال دادند — جواب درست H

Opus	Sol	DS-Flash	Sonnet	Terra	Flash-Lite	Luna
H	H	H	J	J	J	J
۳۱۴ توکن خروجی	۳۴۹ توکن خروجی	۳۳۱۸ توکن خروجی	۳۵۷ توکن خروجی	۹۸۱ توکن خروجی	۵۹۲ توکن خروجی	۴۷ توکن خروجی

چهار مدل روی گزینهٔ J افتادند؛ Terra ۹۸۱ توکن خرج کرد و باز اشتباه — Sol با ۳۴۹ توکن درست زد

این دقیقاً همان جایی است که یک router باید بفهمد سؤال را نباید به ارزان‌ترین مدل بدهد.

از ۷ مدل، چند تا هر سؤال را درست زدند؟



۱۰۵ سؤال (٪۷۰) — هر ۷ مدل درست زدند | ۴۱ سؤال (٪۲۷) — تمام headroom روتینگ اینجاست | ۴ سؤال (٪۳) — هیچ مدلی نتوانست

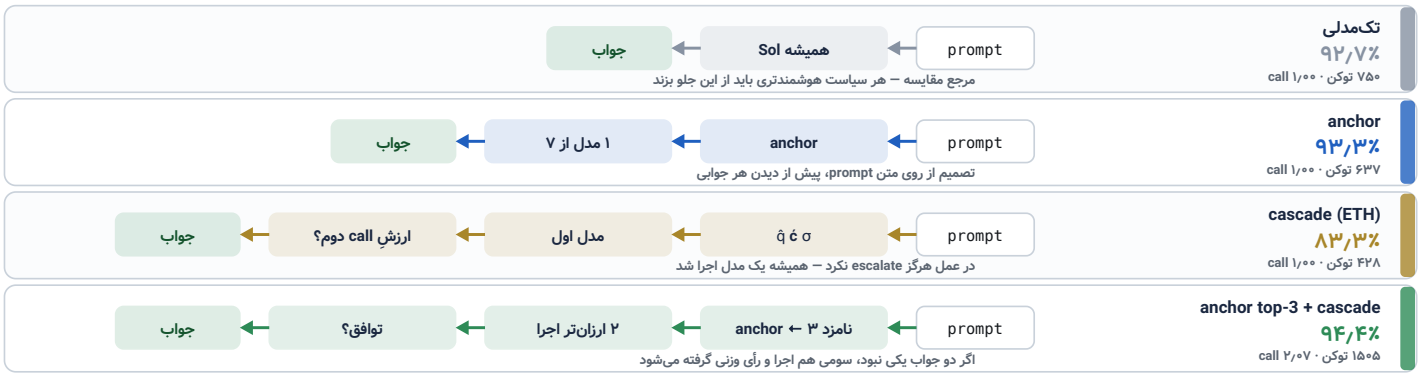
توزیع هر ۱۵۰ سؤال بر حسب اینکه چند مدل درستش زدند. این نمودار سقف کار را تعیین می‌کند: روی ۷۳٪ سؤال‌ها انتخاب مدل اصلاً روی درستی اثر ندارد و فقط هزینه است که فرق می‌کند.

۲. نتایج

مدل یا سیاست	λ	دقت	هزینه (توکن)	call	in	out
GPT-5.6-Sol	—	92.7%	750	1.00	224	207
Claude-Opus-4.6	—	92.0%	1193	1.00	260	346
Claude-Sonnet-4.6	—	89.3%	974	1.00	260	300
DeepSeek-V4-Flash	—	88.7%	2148	1.00	269	945
GPT-5.6-Terra	—	86.0%	782	1.00	224	244
Gemini-3.1-Flash-Lite	—	86.0%	1391	1.00	241	315
GPT-5.6-Luna	—	82.0%	439	1.00	224	67
anchor	0	**93.3%**	637	1.00	—	—
anchor top-3 + cascade	0	**94.4%**	1505	2.07	—	—
anchor	≥.002	**83.3%**	428	1.00	—	—
anchor top-3 + cascade	≥.002	**90.0%**	1226	2.16	—	—
cascade (ETH)	any	**83.3%**	428	1.00	—	—

- `call` — به‌طور میانگین چند مدل برای هر سؤال واقعاً اجرا شد و بابتش پول داده شد.
- `in` — میانگین توکن ورودی، یعنی متن سؤالی که به مدل داده شد.
- `out` — میانگین توکن خروجی، یعنی چیزی که مدل تولید کرد.

۳. چهار سیاستی که مقایسه شدند



اعداد سمت چپ هر نوار، نتیجهٔ اندازه‌گیری‌شده روی ۹۰ سؤال held-out است.

anchor روش اصلی ماست. سؤال‌های گذشته را که جوابشان را می‌دانیم به ۸ گروه تقسیم می‌کند و برای هر گروه نگه می‌دارد که هر مدل چند درصد را درست زده و چند توکن خرج کرده. وقتی سؤال تازه‌ای می‌رسد، شبیه‌ترین گروه پیدا می‌شود و مدلی انتخاب می‌شود که بهترین نسبت دقت به هزینه را روی آن گروه دارد. کل این تصمیم ۰٫۶۴ میلی‌ثانیه طول می‌کشد و هیچ توکنی خرج نمی‌کند.

cascade به روش **ETH** پیاده‌سازی مقالهٔ `A Unified Approach to Routing and Cascading for LLMs` است. علاوه بر تخمین دقت و هزینه، یک عدد سوم هم می‌خواهد: «چقدر به این تخمین مطمئنم». بر همان اساس تصمیم می‌گیرد آیا صدا زدن مدل بعدی ارزشش را دارد یا نه. مزیتش برای ما این بود که به `logprob` نیاز ندارد.

anchor top-3 + cascade ترکیب دو ایده است: اول anchor از میان ۷ مدل سه نامزد برتر را جدا می‌کند، بعد دو تای ارزان‌تر اجرا می‌شوند. اگر جوابشان یکی بود همان سرو می‌شود، وگرنه سومی هم اجرا می‌شود و جوابی که بیشترین وزن کیفیت پشتش است برنده می‌شود. توافق میان مدل‌ها تنها سیگنالی است که بدون logprob در دسترس بود.

> چرا سراغ logprob نرفتیم. روش رایج cascading به اطمینان توکن‌به‌توکن مدل کوچک تکیه می‌کند. probe کردن هر ۹ مدل نشان داد فقط یکی logprob برمی‌گرداند — `DeepSeek-V4-Pro`، که گران‌ترین مدل استخر است. مبدأ یک cascade باید مدل ارزان باشد، پس این مسیر روی این endpoint اصلاً قابل ساخت نبود.

۴. جمع‌بندی

- anchor به‌تنهایی از هر هفت مدل استخر بهتر است. ۹۳٫۳٪ از سؤال‌ها را درست جواب می‌دهد و برای هر سؤال ۶۳۷ توکن خرج می‌کند، در حالی که بهترین مدل استخر `GPT-5.6-Sol` به ۹۲٫۷٪ می‌رسد و ۷۵۰ توکن می‌خورد. یعنی وقتی از روی متن سؤال تصمیم می‌گیریم کدام مدل را صدا بزنیم، هم دقت بالاتر می‌رود و هم هزینه پایین‌تر می‌آید — نه یکی به قیمت آن یکی.
- ترکیب anchor با cascade یک واحد اضافه می‌کند، ولی ۲٫۴ برابر توکن می‌خورد. دقت به ۹۴٫۴٪ می‌رسد، یعنی ۱٫۱ واحد بالاتر. این ۱٫۱ واحد درست روی مرز معناداری است: با ۹۰ سؤال، بازهٔ خطای ما از ۰ تا ۳٫۳ واحد است، پس نمی‌شود مطمئن بود که اثر واقعی صفر نیست. برای مواردی که دقت حرف اول را می‌زند گزینهٔ منطقی است، ولی به‌عنوان حالت پیش‌فرض نه.